**Judul sementara:** Perbandingan Terkontrol Model Klasifikasi Polaritas per Aspek pada Ulasan Google Maps Rumah Makan Berbahasa Indonesia Tidak Baku dan Perambatan Kesalahannya ke Peringkat Prioritas Perbaikan

**Nama:** Belva Fahrozi Chiangmaitri

**NIM:** P31.2025.02702

**Mata kuliah:** Metodologi Penelitian

**Program studi:** Magister Teknik Informatika, Fakultas Ilmu Komputer, Universitas Dian Nuswantoro

**Bidang komputasi:** *Artificial Intelligence* (pemrosesan bahasa alami)

## 1. Permasalahan di Dunia Nyata

Ulasan daring kini menjadi rujukan utama calon pelanggan sebelum memilih tempat makan. Survei Asosiasi Penyelenggara Jasa Internet Indonesia (APJII) 2024 mencatat penetrasi internet Indonesia sebesar 79,5% dari 8.720 responden di 38 provinsi [1], sehingga sebagian besar calon pelanggan dapat membaca dan menulis ulasan di platform seperti Google Maps. Rumah makan keluarga penulis di Semarang tercatat memiliki rata-rata 4,4 bintang dari 2.051 ulasan Google Maps pada 14 Oktober 2026.

Reputasi daring berdampak langsung pada pendapatan. Dengan desain *regression discontinuity* pada data Yelp, Anderson dan Magruder menunjukkan bahwa kenaikan setengah bintang membuat restoran lebih sering terpesan penuh [2]. Temuan ini berasal dari Amerika Serikat, tetapi mekanismenya relevan: bintang mudah dibaca dan dipakai konsumen sebagai jalan pintas keputusan.

Masalahnya, rata-rata bintang tidak menjelaskan aspek mana yang dipuji atau dikeluhkan. Skor 4,4 tidak membedakan keluhan tentang rasa, pelayanan, harga, suasana, atau fasilitas seperti parkir. Bintang juga tidak selalu sejalan dengan isi teks. Valdivia dkk. menemukan bahwa pengulas cenderung memberi nilai positif walaupun kalimat negatif tetap muncul dalam teksnya [3]. Pada 16.156 ulasan objek wisata Sri Lanka, 18,6% ulasan tidak selaras antara bintang dan sentimen teks [4]. Angka itu berasal dari domain lain dan masih berstatus pracetak, sehingga hanya dipakai sebagai petunjuk, bukan sebagai hasil untuk rumah makan.

Gejala yang sama tampak pada cuplikan awal 23 ulasan rumah makan penulis. Cuplikan ini bukan sampel acak, sehingga angkanya hanya ilustratif. Sekitar separuh ulasan menyinggung harga dengan nada keluhan, parkir disebut pada sekitar delapan ulasan, dan dari delapan ulasan yang seluruh sub-ratingnya bintang 5, sekitar empat tetap memuat keluhan eksplisit di dalam teks. Aspek operasional seperti harga, parkir, pembayaran, dan jam buka hanya muncul di teks, bukan di sub-rating. Selain itu, ulasan ditulis dalam bahasa Indonesia tidak baku, dengan singkatan, bahasa gaul, dan campuran bahasa daerah. Membaca lebih dari 2.000 ulasan secara manual memakan waktu dan hasilnya sulit direkap.

Bila masalah ini dibiarkan, keluhan berulang pada aspek tertentu tersembunyi di balik rata-rata bintang yang masih tinggi. Keluhan itu baru terdeteksi setelah rating menurun,

sehingga perbaikan terlambat dan tidak terarah. Pemilik kehilangan dasar untuk memutuskan aspek mana yang perlu diperbaiki lebih dulu. Model pemrosesan bahasa alami sebenarnya dapat merekap ulasan per aspek, tetapi dua hal belum jelas bagi pemilik usaha kecil: model mana yang andal pada ulasan Indonesia tidak baku, dan seberapa jauh kesalahan model mengubah keputusan prioritas perbaikan. Dua hal inilah yang mendasari penelitian ini.

## 2. Solusi yang Telah Ada Saat Ini

**Solusi 1: rata-rata bintang dan pembacaan ulasan secara manual (non-komputasi).** Platform menampilkan rata-rata bintang, dan pemilik membaca serta membalas ulasan satu per satu. Pendekatan ini berhasil memberi gambaran umum reputasi, dan sinyal bintang terbukti bernilai ekonomi [2]. Namun, rata-rata tidak memisahkan aspek, dan pembacaan manual tidak dapat diskalakan.

**Solusi 2: ABSA klasik dengan TF-IDF dan *support vector machine* (SVM).** Firdaus dkk. menganalisis 1.029 ulasan Google Review tahun 2021–2022 sebuah depot makan dengan pembobotan TF-IDF dan SVM, dan melaporkan rata-rata akurasi sekitar 92% pada validasi silang *k-fold* [5]. Pendekatan ini murah dan cukup akurat, tetapi diuji pada satu rumah makan dan dilaporkan terutama dengan akurasi.

**Solusi 3: ABSA dengan IndoBERT.** Sirait dan Silitonga menerapkan klasifikasi pasangan kalimat IndoBERT pada 1.080 ulasan satu rumah makan dengan lima kategori aspek, lengkap dengan dasbor interaktif, dan melaporkan akurasi sentimen 90,00% dengan F1 makro 85,56% [6]. Perwira dkk. menyetel IndoBERT pada 20.000 ulasan Google tempat wisata dan melaporkan presisi deteksi aspek 0,85–0,89 [7]. Yulianti dan Nissa membandingkan klasifikasi kalimat tunggal dan pasangan kalimat pada ulasan pelanggan berbahasa Indonesia [8]. Model dasarnya adalah IndoBERT dari IndoLEM [9], sedangkan IndoBERTweet [10] dilatih khusus pada teks media sosial yang lebih informal.

**Solusi 4: model bahasa besar (*large language model*, LLM).** Carrasco dan Dias membandingkan BART, DeBERTa, dan ChatGPT untuk ABSA ulasan restoran dan menemukan bahwa ChatGPT memperoleh F1 tertinggi terhadap klasifikasi manusia [11]. Sebaliknya, Bai dkk. menunjukkan bahwa pada ABSA gabungan LLM mengungguli metode terawasi dengan sedikit contoh, tetapi umumnya masih tertinggal dari metode

terawasi terbaik [12]. Kedua temuan ini tidak sepenuhnya searah, sehingga keunggulan LLM bergantung pada tugas, bahasa, dan cara pengujian.

**Solusi 5: sistem pemantauan dan analisis prioritas berbasis ulasan.** Carrasco dan Dias membangun aplikasi RestMON Algarve di atas 880.000 ulasan dari 1.581 restoran agar manajer dapat memantau sentimen per atribut, melihat perubahannya dari waktu ke waktu, dan membandingkan pesaing [11]. Sukwadi dkk. menggabungkan analisis sentimen dan emosi berbasis aspek dari Google Review dengan kuesioner 100 responden dan *importance performance analysis* (IPA) tiga dimensi untuk meningkatkan layanan jaringan restoran cepat saji di Indonesia [13].

**Penilaian umum.** Sistem pemantauan ulasan berbasis ABSA dapat merangkum keluhan per aspek dan menampilkannya kepada pengelola. Namun, metrik klasifikasi seperti akurasi atau F1 hanya mengukur kecocokan label, belum memastikan bahwa urutan aspek yang disarankan sistem sesuai dengan urutan yang diperoleh dari label manusia. Keterbatasan evaluasi hilir inilah yang menjadi fokus kritik dan penelitian ini.

## 3. Perspektif Komputasi

**Bidang dan perumusan masalah.** Masalah ini berada dalam bidang *Artificial Intelligence*, khususnya pemrosesan bahasa alami (*natural language processing*). Persoalannya dirumuskan sebagai klasifikasi polaritas per kategori aspek (*aspect category sentiment classification*), yaitu tugas ABSA yang menetapkan sentimen untuk setiap kategori aspek yang disebut dalam ulasan [14]. Lima aspek ditetapkan: makanan, pelayanan, harga, suasana, serta fasilitas dan akses (parkir, pembayaran, jam buka). Polaritas tiap aspek berupa positif, netral atau campuran, dan negatif, ditambah label tidak disebut. Tiga kelas dipilih karena ulasan nyata sering bernada campuran dalam satu aspek, sedangkan tujuan akhirnya adalah keputusan bisnis, bukan sekadar skor sentimen.

**Input, proses, dan output.**

- **Input:** teks ulasan Google Maps berbahasa Indonesia tidak baku beserta tanggalnya. Rating bintang tidak dipakai sebagai variabel dalam model.
- **Proses:** (1) membentuk dua versi teks yang sama, yaitu teks asli dan teks yang dinormalisasi dengan kamus singkatan/bahasa gaul; (2) mengklasifikasikan polaritas per aspek menggunakan dua model: SVM dengan TF-IDF sebagai

*baseline* [5] dan IndoBERT yang disetel (*fine-tuned*) [9]; (3) menghitung skor prioritas deskriptif untuk setiap aspek. Satu ulasan dihitung paling banyak satu kali per aspek; skor adalah jumlah dan proporsi ulasan berlabel negatif pada aspek tersebut. Kedua model diuji pada kedua kondisi teks dengan pembagian data yang sama.

- **Output:** label polaritas per aspek dan peringkat deskriptif aspek berdasarkan jumlah/proporsi ulasan negatif. Peringkat dari prediksi model dibandingkan dengan peringkat dari label manusia. Skor ini hanya proksi banyaknya keluhan, bukan ukuran tingkat kepentingan pelanggan, dampak finansial, atau bukti bahwa suatu aspek menyebabkan rating turun.

**Tabel 1.** Riset terdahulu yang relevan (2021–2026)

| **Penulis (tahun)** | **Metode** | **Data** | **Hasil utama** |
|---|---|---|---|
| Firdaus dkk. (2024) [5] | TF-IDF dan SVM; ABSA | 1.029 ulasan Google Review satu depot makan, 2021–2022 | Rata-rata akurasi sekitar 92% (validasi silang *k-fold*) |
| Carrasco dan Dias (2024) [11] | BART, DeBERTa, ChatGPT; aplikasi RestMON | Sampel uji 1.000 ulasan; aplikasi pada 880.000 ulasan dari 1.581 restoran di Algarve | BART mengungguli DeBERTa; ChatGPT memperoleh F1 tertinggi |
| Sukwadi dkk. (2025) [13] | Sentimen dan emosi berbasis aspek, TF-IDF, IPA tiga dimensi | Google Review dan kuesioner 100 responden; restoran cepat saji Indonesia | Identifikasi atribut layanan untuk perbaikan |
| Perwira dkk. (2025) [7] | *Fine-tuning* IndoBERT untuk ABSA | 20.000 ulasan Google, destinasi wisata | Presisi deteksi aspek 0,85–0,89 |
| Sirait dan Silitonga (2026) [6] | IndoBERT, klasifikasi pasangan kalimat, dasbor | 1.080 ulasan satu rumah makan, lima aspek | Akurasi sentimen 90,00%, F1 makro 85,56% |
| Yulianti dan Nissa (2024) [8] | IndoBERT, kalimat tunggal dan pasangan kalimat | Ulasan pelanggan berbahasa Indonesia | Pasangan kalimat paling efektif; kalimat tunggal terbaik bila efisiensi diperhitungkan |
| Bai dkk. (2024) [12] | LLM (ChatABSA) untuk ABSA gabungan | *Benchmark* ABSA gabungan | Unggul atas metode terawasi sedikit contoh; umumnya di bawah kinerja terbaik terawasi |
| Patil dkk. (2026) [15] (pracetak) | LLM untuk identifikasi aspek, pengklasifikasi untuk sentimen | 4,7 juta ulasan restoran selama 17 tahun | Aspek hasil mesin menjelaskan variasi rating keseluruhan |
| Nurdiansyah dan Dewi (2023) [16] | SVM, *Information Gain*, kamus slang/singkatan, dan koreksi Peter Norvig | 1.020 ulasan produk kecantikan; *10-fold cross-validation* | Akurasi terbaik 83% tanpa koreksi Peter Norvig; koreksi kata tertentu menimbulkan kesalahan |

| Penulis (tahun) | Metode | Data | Hasil utama |
|---|---|---|---|
| Latifah dkk. (2026) [17] | *Fine-tuning* IndoBERT; ABSA | 3.232 ulasan Google Review dari lima restoran Sunda; lima aspek | F1 makro >0,91; tidak melaporkan uji normalisasi atau kesesuaian peringkat terhadap label manusia |

Tabel 1 menunjukkan bahwa penelitian terdahulu telah menerapkan ABSA pada ulasan restoran dan bahasa Indonesia, tetapi umumnya menilai keluaran dengan metrik klasifikasi. Penelitian ini mempersempit fokus pada satu pertanyaan lanjutan: apakah peringkat aspek berdasarkan prediksi model sejalan dengan peringkat dari label manusia, dan apakah normalisasi mengubah hasil itu?

**Implikasi bagi rancangan.** Penelitian ini menggunakan dua model yang realistis untuk dibandingkan pada data berlabel terbatas: SVM-TF-IDF sebagai *baseline* yang ringan [5] dan IndoBERT sebagai model bahasa Indonesia [9]. LLM tidak dimasukkan ke eksperimen utama agar jumlah kombinasi eksperimen dan beban validasi tetap terkelola. Penelitian tidak membuat model baru; kontribusinya adalah perbandingan terkontrol kondisi teks asli dan ternormalisasi serta evaluasi kesesuaian peringkat aspek.

### 4. Kritik terhadap Satu Solusi

Solusi yang dikritik adalah sistem pemantauan restoran yang mengelompokkan ulasan dengan ABSA lalu menyajikan hasilnya sebagai dukungan keputusan manajer, seperti RestMON [11]. Kritik tidak ditujukan pada manfaat pemantauan atau ABSA secara umum, melainkan pada bukti bahwa keluaran sistem dapat dipakai untuk mengurutkan aspek yang perlu diperbaiki.

**Kelebihan.** Sistem seperti RestMON merangkum sentimen menurut atribut dan memantau perubahannya, sehingga pengelola tidak harus membaca semua ulasan satu per satu. Skalanya juga besar: studi tersebut menerapkan sistem pada sekitar 880.000 ulasan dari 1.581 restoran [11]. Ini menunjukkan potensi ABSA untuk pemantauan operasional.

**Keterbatasan beserta bukti.** Evaluasi kinerja klasifikasi belum sama dengan validasi rekomendasi prioritas.

1. Metrik klasifikasi belum memvalidasi urutan prioritas. Akurasi atau F1 menunjukkan kecocokan label aspek/sentimen, tetapi tidak menjawab apakah aspek yang ditempatkan pada urutan teratas oleh sistem sama dengan aspek teratas

menurut label manusia. RestMON menunjukkan kemampuan pemantauan skala besar [11], tetapi artikel tersebut tidak melaporkan evaluasi kesesuaian peringkat prioritas model terhadap peringkat dari label manusia. Karena itu, keluaran *dashboard* berguna sebagai ringkasan, tetapi dasar untuk menyebutnya rekomendasi prioritas masih perlu diuji.

2. Batas kritik ini adalah bahwa belum tersedianya evaluasi peringkat bukan bukti bahwa prioritas yang dihasilkan pasti salah. Artinya, kesesuaiannya belum ditunjukkan. Penelitian ini akan menguji hal tersebut secara langsung pada data rumah makan penulis, bukan mengklaim bahwa hasilnya berlaku untuk semua restoran.
3. Batas penerapan. RestMON menggunakan data restoran di Algarve [11], sehingga bahasa dan konteksnya berbeda dari ulasan rumah makan berbahasa Indonesia tidak baku. Ini membatasi pemindahan hasil ke objek penelitian ini, tetapi bukan kritik utama terhadap kemampuan sistem.
4. Studi terdekat dan batas gap. Latifah dkk. (2026) telah menerapkan IndoBERT pada 3.232 ulasan dari lima restoran Sunda, dengan aspek makanan, pelayanan, harga, suasana, dan fasilitas [17]. Karena itu, penelitian ini tidak mengklaim sebagai studi ABSA restoran Indonesia pertama. Artikel tersebut melaporkan metrik klasifikasi dan perbandingan aspek antarrestoran, tetapi tidak melaporkan uji terkontrol teks asli versus ternormalisasi atau kesesuaian peringkat prediksi terhadap label manusia. Gap penelitian ini dipersempit pada dua evaluasi tersebut. Normalisasi ABSA Bahasa Indonesia pada domain produk kecantikan juga pernah diteliti; koreksi kata tertentu justru dapat menambah kesalahan [16].
5. Dengan demikian, keterbatasan yang diuji dalam penelitian ini spesifik: sistem pemantauan ABSA seperti RestMON telah menunjukkan kemampuan merangkum ulasan, tetapi kesesuaian urutan prioritas dari prediksinya terhadap label manusia belum dilaporkan [11]. Skor prioritas penelitian ini juga sengaja dibatasi sebagai frekuensi keluhan, bukan pengganti survei kepentingan pelanggan atau analisis dampak bisnis.

**Celah penelitian.** Latifah dkk. telah menerapkan IndoBERT pada ulasan lima restoran Sunda dengan lima kategori aspek [17], sehingga konteks ABSA restoran Indonesia sudah memiliki studi langsung. Namun, belum ditemukan perbandingan terkontrol teks

asli dan ternormalisasi pada korpus rumah makan Indonesia tidak baku, ataupun evaluasi apakah peringkat aspek dari prediksi model sesuai dengan peringkat dari anotasi manusia [11,17]. Penelitian ini menguji dua model pada dua kondisi teks dan mengukur *macro-F1* serta kesesuaian peringkat frekuensi ulasan negatif. Normalisasi ABSA Bahasa Indonesia pernah diteliti pada ulasan produk kecantikan [16], tetapi hasil domain tersebut belum otomatis berlaku untuk ulasan restoran. Gap dibatasi pada literatur yang ditelaah.

**5. Riset Lain yang Relevan dengan Kritik**

Empat riset berikut memberi konteks bagi keterbatasan evaluasi hilir dan normalisasi yang menjadi fokus penelitian.

**Carrasco dan Dias (2024).** Mereka menguji pendekatan BART, DeBERTa, dan ChatGPT pada sampel 1.000 ulasan yang juga diberi label oleh tiga kelompok manusia. ChatGPT 4 memperoleh F1 0,77 dan *macro-F1* 0,88; kesesuaian antarpenilai manusia berada pada kisaran F1 0,83–0,92 [11]. Penelitian itu juga membangun RestMON untuk menampilkan sentimen atribut dan perubahannya bagi pengelola. Namun, artikel tersebut tidak melaporkan apakah peringkat prioritas operasional dari prediksi model sesuai dengan prioritas yang dihitung dari label manusia. Karena itu, penelitian ini dapat menambahkan evaluasi khusus pada kesesuaian peringkat aspek.

**Sukwadi dkk. (2025).** Mereka menggabungkan ABSA Google Review dengan IPA dari kuesioner 100 responden [13]. Studi ini menunjukkan cara mengubah hasil analisis menjadi prioritas layanan, tetapi belum menguji apakah peringkat aspek dari prediksi model stabil terhadap kesalahan klasifikasi. Penelitian ini menguji kesesuaian peringkat secara terukur, dengan menyebutnya sinyal keluhan, bukan tingkat kepentingan pelanggan.

**Latifah dkk. (2026).** Mereka menerapkan IndoBERT pada lebih dari 3.000 ulasan Google dari lima restoran Sunda dan menganalisis lima aspek [17]. Studi ini sangat dekat dengan objek dan model penelitian yang diusulkan, sehingga menjadi pembanding utama. Namun, fokusnya pada performa klasifikasi dan perbandingan antarrestoran; uji efek normalisasi dan evaluasi kesesuaian peringkat model terhadap label manusia tidak dilaporkan. Oleh sebab itu, penelitian ini perlu diposisikan sebagai pengembangan evaluasi, bukan pengenalan ABSA pada restoran Indonesia.

**Firdaus dkk. (2024).** Mereka melaporkan ABSA SVM pada ulasan satu depot makan [5]. Studi ini relevan sebagai dasar pemilihan SVM *baseline*, tetapi belum membandingkan kondisi teks mentah dan ternormalisasi secara terkontrol maupun memeriksa kesesuaian peringkat aspek terhadap label manusia.

Ringkasnya, studi terdahulu telah menerapkan IndoBERT-ABSA pada beberapa restoran Indonesia, termasuk lima restoran Sunda [17]. Penelitian yang diusulkan tidak mengulang klaim tersebut; fokusnya adalah menguji normalisasi pada ulasan tidak baku serta apakah peringkat frekuensi keluhan dari prediksi SVM/IndoBERT selaras dengan anotasi manusia. Dua model, dua kondisi teks, dan satu korpus berlabel menjaga ruang lingkup tetap realistis.

## 6. Pernyataan Riset

**Rumusan masalah.** Pemilik rumah makan memerlukan ringkasan keluhan per aspek dari ulasan Google Maps berbahasa Indonesia tidak baku. Belum diketahui apakah normalisasi kamus mengubah kinerja SVM dan IndoBERT pada data tersebut, serta apakah peringkat aspek berdasarkan prediksi kedua model sesuai dengan peringkat berdasarkan anotasi manusia. Peringkat yang dimaksud adalah frekuensi ulasan negatif per aspek, sebagai sinyal awal untuk ditinjau pemilik, bukan keputusan final tentang kepentingan atau dampak bisnis.

**Pertanyaan penelitian.**

- **RQ1.** Bagaimana perbedaan *macro-F1* SVM-TF-IDF dan IndoBERT untuk klasifikasi polaritas per aspek pada teks asli dan teks yang dinormalisasi?
- **RQ2.** Seberapa sesuai peringkat aspek berdasarkan frekuensi ulasan negatif dari prediksi masing-masing model dengan peringkat yang dihitung dari label manusia?

**Tujuan penelitian.**

1. Membandingkan SVM-TF-IDF dan IndoBERT pada teks asli dan ternormalisasi menggunakan *macro-F1* per aspek (menjawab RQ1).
2. Mengukur kesesuaian peringkat frekuensi ulasan negatif dari prediksi model terhadap peringkat dari label manusia (menjawab RQ2).

**Hipotesis kerja.** H1: IndoBERT menghasilkan *macro-F1* lebih tinggi daripada SVM-TF-IDF, tetapi besar perbedaannya bergantung pada kondisi normalisasi. H2: normalisasi kamus mengubah kinerja setidaknya pada salah satu model. Hasil tetap dilaporkan sebagai temuan empiris, termasuk bila hipotesis tidak didukung.

**Usulan pendekatan, data, dan ukuran keberhasilan.**

**Data.** Data berasal dari ulasan Google Maps rumah makan penulis (sekitar 2.000 ulasan) yang dapat diakses melalui akun pemilik/pengelola yang terverifikasi dan berizin. Pengambilan melalui Google Business Profile API hanya dilakukan bila akses API dan otorisasi tersedia; jika tidak, metode ekspor yang diizinkan dan dapat didokumentasikan digunakan. Ulasan dianonimkan. Sebanyak 300–500 ulasan dipilih secara acak berstrata menurut periode untuk dianotasi sebagai *gold set*. Sedikitnya 20% anotasi diperiksa dua penilai; kesepakatan dilaporkan dengan *Cohen's kappa* per aspek atau label yang relevan.

**Skema aspek dan label.** Aspek awal adalah makanan, pelayanan, harga, dan suasana, sesuai kategori umum yang digunakan studi ulasan restoran. Fasilitas/akses (misalnya parkir, pembayaran, jam buka) dipertahankan hanya jika *pilot* acak menunjukkan jumlah penyebutan yang memadai; jika tidak, aspek itu dilaporkan deskriptif atau digabung ke kategori fasilitas. Satu unit anotasi adalah satu ulasan untuk satu aspek. Labelnya: tidak disebut, positif, netral/campuran, atau negatif. Pedoman anotasi mencatat negasi, campuran bahasa, dan keluhan halus. Frekuensi dari sampel *pilot* dilaporkan sebelum skema final ditetapkan.

**Model.** Eksperimen utama memakai (1) SVM dengan TF-IDF sebagai *baseline* ringan [5] dan (2) IndoBERT yang disetel [9]. Setiap model diuji pada teks asli dan teks hasil normalisasi kamus. IndoBERTweet dan LLM tidak dimasukkan ke eksperimen utama agar komputasi, anotasi, dan pengujian tetap sesuai skala tugas. Versi perangkat lunak, parameter, dan kamus normalisasi akan dicatat agar eksperimen dapat diulang.

**Pencegahan kebocoran data.** Pembagian data dilakukan pada tingkat ulasan sebelum pelatihan atau penyetelan model. Kedua kondisi teks memakai pembagian ulasan yang identik. Kamus normalisasi ditetapkan tanpa melihat label pada data uji; seluruh pilihan parameter dilakukan hanya pada data latih/validasi.

**Evaluasi RQ1.** Gunakan validasi silang berstrata yang sama untuk kedua model dan kedua kondisi teks. Metrik utama adalah *macro-F1* per aspek; precision, recall, dan

akurasi menjadi pelengkap. Selang kepercayaan perbedaan skor dapat dihitung dengan *bootstrap* pada tingkat ulasan.

**Evaluasi RQ2.** Untuk setiap aspek, hitung jumlah ulasan unik yang berlabel negatif dan proporsinya dari seluruh ulasan *gold set*. Satu ulasan dihitung satu kali per aspek agar pengulangan kata dalam ulasan tidak menaikkan skor. Urutkan skor dari anotasi manusia dan prediksi tiap model/kondisi teks; laporkan tumpang tindih dua aspek teratas dan korelasi Kendall τ. Laporkan pula *bootstrap* untuk menunjukkan ketidakpastian urutan. Peringkat ini adalah indikator volume keluhan, bukan bobot kepentingan atau dampak finansial.

**Kelayakan.** Data ulasan telah tersedia. Pilot anotasi dilakukan terlebih dahulu untuk mengukur waktu nyata dan memperjelas pedoman; ukuran *gold set* 300–500 ulasan kemudian disesuaikan dengan waktu yang tersedia. SVM dapat dijalankan pada komputer biasa, sedangkan IndoBERT dapat memakai GPU lokal atau komputasi awan bila tersedia.

**Keterbatasan.** Data berasal dari satu rumah makan sehingga hasil tidak langsung digeneralisasi ke restoran lain. Peringkat berbasis frekuensi tidak mengukur kepentingan pelanggan, tingkat keparahan, atau dampak terhadap omzet. Kesimpulan dibatasi pada kestabilan ringkasan model terhadap label manusia pada data yang diuji.

**Risiko dan mitigasi.** Anotasi bersifat subjektif; karena itu digunakan pedoman tertulis, *pilot* anotasi, dan pemeriksaan ganda pada sedikitnya 20% data. Jika distribusi label tidak seimbang, *macro-F1* dilaporkan selain akurasi dan jumlah tiap kelas disajikan. Nama pengulas dianonimkan dan teks mentah tidak dipublikasikan.

**Luaran yang diharapkan.** (1) Bukti terkontrol tentang model yang layak dipakai untuk ulasan rumah makan Indonesia tidak baku beserta efek normalisasinya. (2) Ukuran seberapa kuat peringkat prioritas bertahan terhadap kesalahan model. (3) Peringkat prioritas perbaikan aspek bagi pemilik rumah makan.

**Daftar Pustaka**


1. Asosiasi Penyelenggara Jasa Internet Indonesia (APJII). Pengguna internet di Indonesia meningkat di 2024 [Internet]. Jakarta: APJII; 2024 Feb 7 [dikutip 15 Okt 2026]. Tersedia pada: https://www.apjii.id/berita/d/pengguna-internet-di-indonesia-meningkat-di-2024

2. Anderson M, Magruder J. Learning from the crowd: regression discontinuity estimates of the effects of an online review database. Econ J. 2012;122(563):957–89. doi:10.1111/j.1468-0297.2012.02512.x

3. Valdivia A, Hrabova E, Chaturvedi I, Luzón MV, Troiano L, Cambria E, et al. Inconsistencies on TripAdvisor reviews: a unified index between users and sentiment analysis methods. Neurocomputing. 2019;353:3–16. doi:10.1016/j.neucom.2018.09.096

4. Abaiyan R, Sutharsan R, Amantha K, Krishnathas A, Rauff A, Sriyathurshan K, et al. Fault of our stars: behavioral drivers of rating–sentiment incongruence [Internet]. arXiv:2606.25518 [pracetak]. 2026 [dikutip 15 Okt 2026]. Tersedia pada: https://arxiv.org/abs/2606.25518

5. Firdaus MF, Ratnawati DE, Setiawan NY. Analisis sentimen berbasis aspek pada ulasan pelanggan restoran menggunakan algoritma support vector machine (studi kasus: Depot Bamara). J Teknol Inf dan Ilmu Komput. 2024;11(6):1265–72. doi:10.25126/jtiik.2024117564

6. Sirait VV, Silitonga PDP. Implementasi model IndoBERT untuk analisis sentimen berbasis aspek dan visualisasinya pada dashboard interaktif ulasan restoran. Jurnal ICT: Information Communication & Technology. 2026;26(1):231–42. doi:10.36054/jict-ikmi.v26i1.382

7. Perwira RI, Permadi VA, Purnamasari DI, Agusdin RP. Domain-specific fine-tuning of IndoBERT for aspect-based sentiment analysis in Indonesian travel user-generated content. J Inf Syst Eng Bus Intell. 2025;11(1):30–40. doi:10.20473/jisebi.11.1.30-40

8. Yulianti E, Nissa NK. ABSA of Indonesian customer reviews using IndoBERT: single-sentence and sentence-pair classification approaches. Bull Electr Eng Inform. 2024;13(5):3579–89. doi:10.11591/eei.v13i5.8032

9. Koto F, Rahimi A, Lau JH, Baldwin T. IndoLEM and IndoBERT: a benchmark dataset and pre-trained language model for Indonesian NLP. In: Proceedings of the 28th International Conference on Computational Linguistics. 2020. p. 757–70.

10. Koto F, Lau JH, Baldwin T. IndoBERTweet: a pretrained language model for Indonesian Twitter with effective domain-specific vocabulary initialization. In: Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 2021. p. 10660–8.

11. Carrasco P, Dias S. Enhancing restaurant management through aspect-based sentiment analysis and NLP techniques. Procedia Comput Sci. 2024;237:129–37. doi:10.1016/j.procs.2024.05.088

12. Bai Y, Han Z, Zhao Y, Gao H, Zhang Z, Wang X, et al. Is compound aspect-based sentiment analysis addressed by LLMs? In: Findings of the Association for Computational Linguistics: EMNLP 2024. 2024. p. 7836–61. doi:10.18653/v1/2024.findings-emnlp.460

13. Sukwadi R, Silitonga RM, Inderawati MMW, Octavian F, Jou YT, Thu NTB. Peningkatan kualitas layanan jaringan restoran cepat saji Indonesia: analisis sentimen dan emosi berbasis aspek. J Teknol Inf dan Ilmu Komput. 2025;12(2):359–68. doi:10.25126/jtiik.2025129416

14. Zhang W, Li X, Deng Y, Bing L, Lam W. A survey on aspect-based sentiment analysis: tasks, methods, and challenges. IEEE Trans Knowl Data Eng. 2023;35(11):11019–38. doi:10.1109/TKDE.2022.3230975

15. Patil V, Bacha SV, Yamani R, Sun Y, Kejriwal M. Beyond the star rating: a scalable framework for aspect-based sentiment analysis using LLMs and text classification [Internet]. arXiv:2602.21082 [pracetak]. 2026 [dikutip 15 Okt 2026]. Tersedia pada: https://arxiv.org/abs/2602.21082

16. Nurdiansyah RL, Dewi KE. Pengaruh information gain dan normalisasi kata pada analisis sentimen berbasis aspek. Komputa. 2023;12(2):80–90. doi:10.34010/komputa.v12i2.9449

17. Latifah S, Erfina A, Warman C. Perbandingan hasil aspect-based sentiment analysis pada ulasan Google Review restoran Sunda di Bogor menggunakan fine-tuning IndoBERT. Dinamik. 2026;31(1):323–34. doi:10.35315/dinamik.v31i1.10417